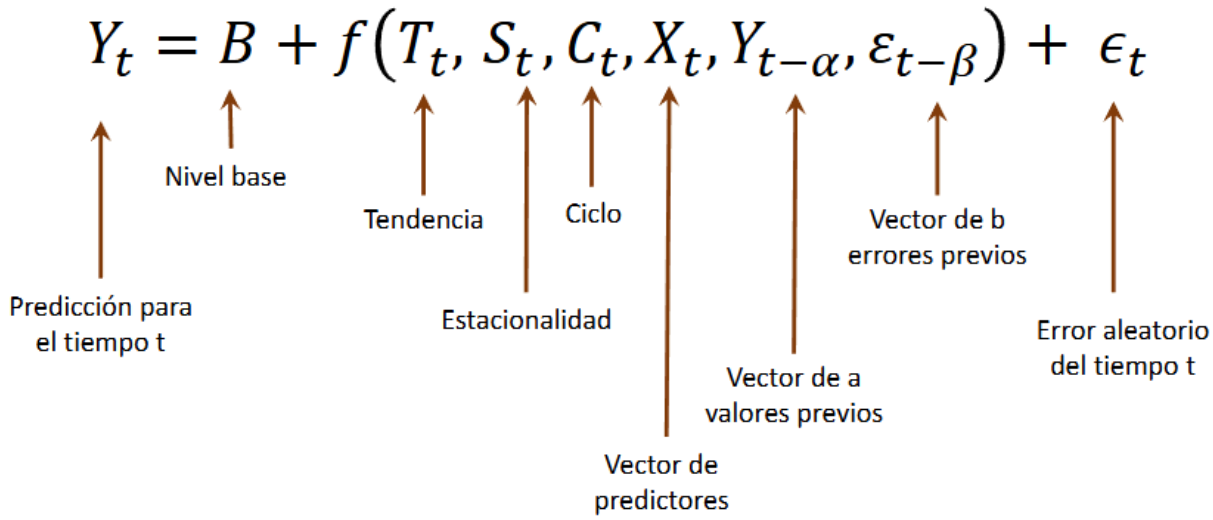
Clase 15

Series de tiempo

¿Cómo manejar el factor tiempo? ¿Qué hago cuando mis bases de datos son momentos en el tiempo?

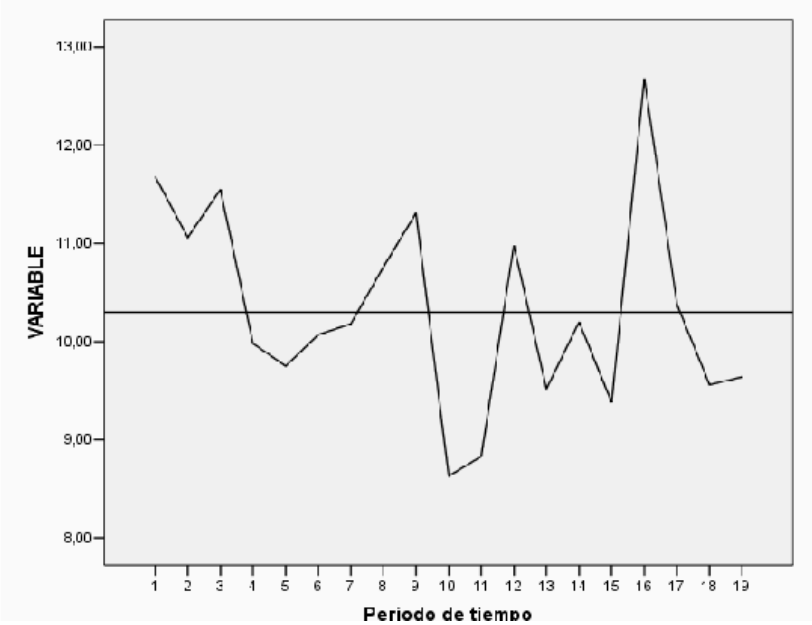
Entran a jugar posibilidades nuevas:



Son cinco elementos nuevos.

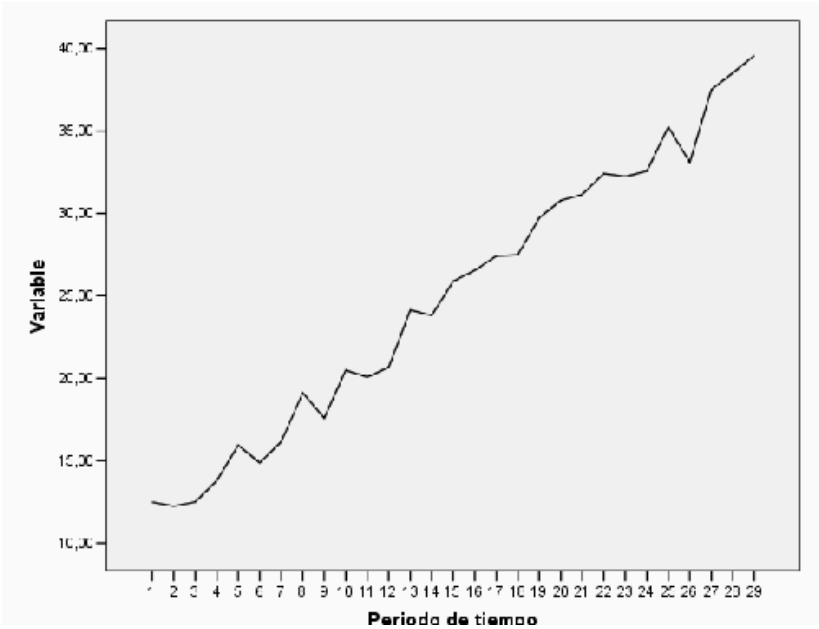
1. Series con nivel base, una primera posibilidad en la que digamos que mis datos no varían con el tiempo (estacionareidad)

Series con nivel base



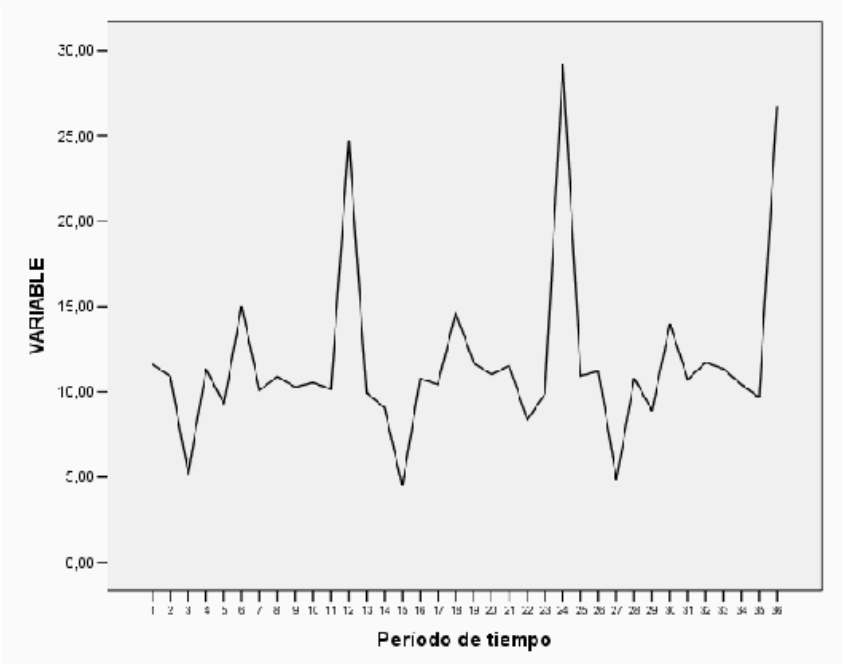
2. Lo que estamos midiendo asciende o desciende en el tiempo (tendencia)

Series con base y tendencia



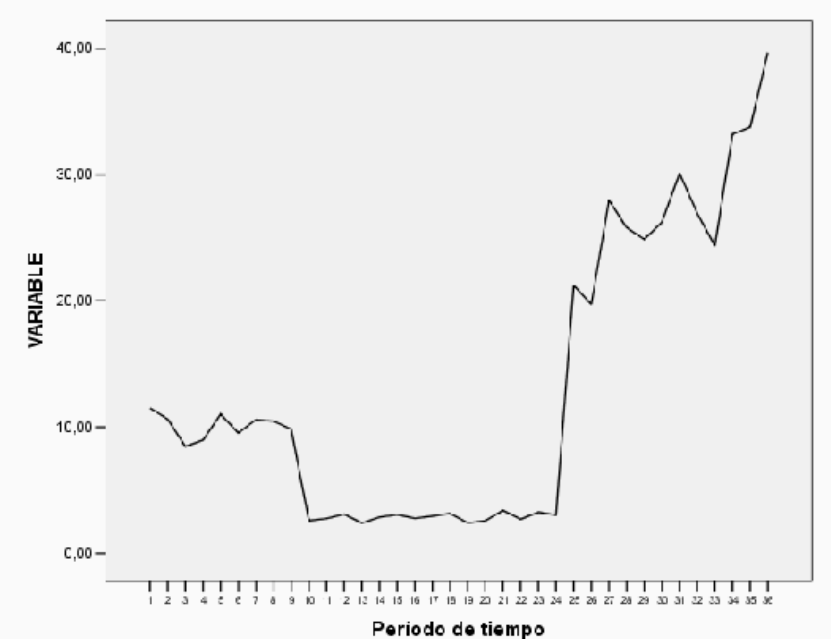
3. Combinación de un factor base y **estacionalidad**, cada cierta cantidad de tiempo se repite un patrón.

Series con base y factor estacional



4. Ciclos, rupturas en el tiempo (ejemplo, la pandemia)

Series con base y ciclos



Todo esto son formas de modelar el tiempo.

Autocorrelación:

¿Cómo me asocio yo con los datos del pasado? ¿Qué tan lejos me voy al pasado? Ej. Mi yo de ayer se parece a mi yo de hoy; pero ¿mi yo de hoy se parece a mi yo de hace 25 años?

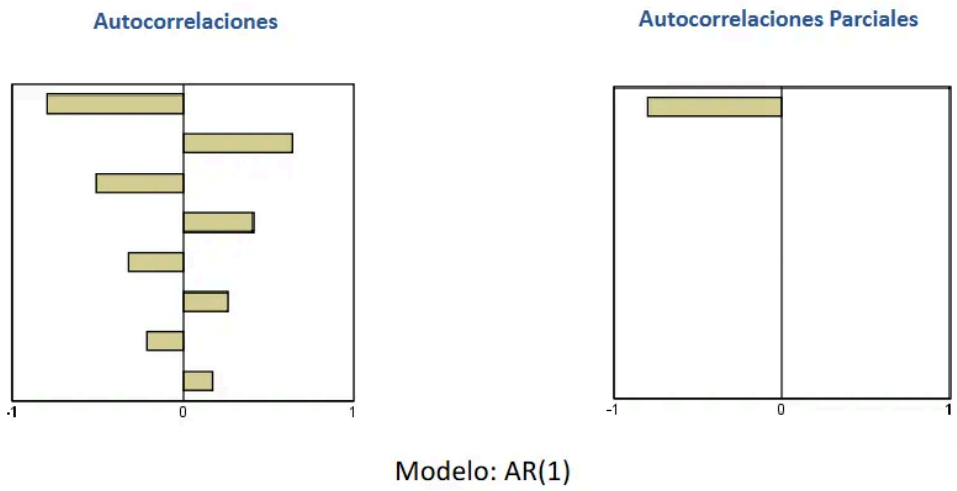
Autocorrelación parcial:

Si yo me autocorrelaciono con el pasado y esa autocorrelación no depende de los puntos intermedios.

Es decir: yo necesito datos del pasado que no están explicados por los datos intermedios (Ej, desde mi tatarabuelo no había un artista en la familia y yo soy artista)

Los datos en el tiempo son multicolineales.

Tendencias, Estacionalidades, Ciclos, Autocorrelaciones y Autocorrelaciones parciales



Aquí va un **ejemplo súper ilustrativo**, usando una historia sencilla y concreta para que la diferencia entre **autocorrelación (ACF)** y **autocorrelación parcial (PACF)** te quede totalmente clara.

🍽️ Ejemplo ilustrativo: Recetas de cocina

Imagina que quieres saber qué ingredientes hacen que una sopa quede salada.

Tu serie de tiempo es:

- (X_t): nivel de sal en la sopa del día (t)

Y sospechas que depende de:

- cuánta sal pusiste hoy (lag 0)
- cuánta sal pusiste ayer (lag 1)
- cuánta sal pusiste hace dos días (lag 2)
- etc.

🧂 Autocorrelación (ACF): el efecto total

La autocorrelación te dice:

> "¿Qué tanta relación hay entre la sal de hoy y la sal de hace k días,
> tomando en cuenta todo, incluso el efecto en cadena?"

Ejemplo:

- La sal de hoy depende mucho de la sal de ayer.
- Y la sal de ayer dependió a su vez de la sal de antier.

Entonces, aunque la sal de hoy **no dependa directamente** de la de antier,

la ACF en lag 2 será grande

porque el efecto viaja así:

Antier → Ayer → Hoy.

➡️ La ACF no distingue si la relación es **directa** o **indirecta**, solo mide que existe.

✂️ Autocorrelación parcial (PACF): el efecto puro y directo

La autocorrelación parcial te dice:

> "Si quitamos por completo el efecto de la sal de ayer,
>
> ¿sigue habiendo relación entre la sal de hoy y la de antier?"

O sea:

- ¿La sal de antier influye **directamente**?
- ¿O su efecto solo se debe a que afectó la sal de ayer?

Si la respuesta es:

"No afecta directamente; solo afecta a través de ayer",

entonces la PACF será ≈ 0.

➡️ La PACF *elimina* los efectos intermedios (como la sal de ayer) para ver si hay influencia *pura*.

🎯 Ejemplo concreto con números

Supongamos que la sal sigue este patrón:

[

X_t = 0.7 X_{t-1} + \varepsilon_t

]

Es decir:

- lo de hoy depende solo de ayer
- no depende de antier directamente

🔹 Resultados

ACF:

- lag 1 → 0.7
- lag 2 → 0.7 × 0.7 = 0.49
- lag 3 → $0.7^3 = 0.343$

- ...

➡️ Declina poco a poco porque incluye efectos indirectos.

PACF:

- lag 1 → 0.7 (efecto directo)
- lag 2 → ~0 (porque solo influye a través de ayer)
- lag 3 → ~0
- ...

➡️ Solo aparece el lag directamente relevante.

🧠 La diferencia en una frase

ACF	PACF
Mide **toda** la relación (directa + indirecta) entre (X_t) y (X_{t-k}).	Mide **solo la relación directa**, eliminando lo que pasa a través de otros lags.
Se "apaga" lentamente.	Se "corta" donde ya no hay relación directa.

👀 Visualización mental (muy clara)

Imagina que la influencia viaja como fichas de dominó:

- ACF ve que la ficha 3 hizo caer la 1 **aunque sea por cadena**.
- PACF solo cuenta si la ficha 3 empuja **directamente** la ficha 1.

Entrenamiento y validación

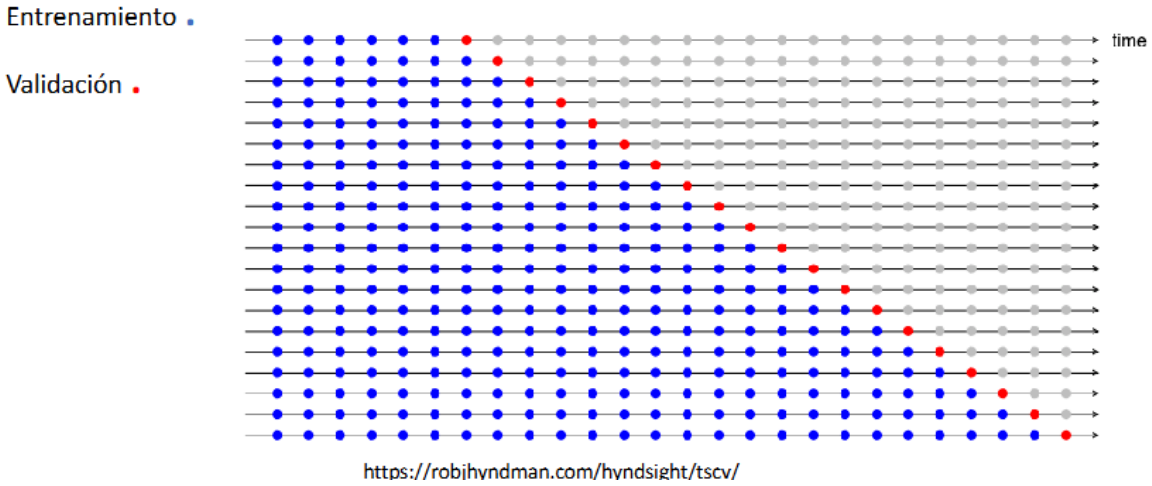
Este problema me obliga a repensar train y test. Dada la naturaleza temporal de los datos, entrenamiento y validación no pueden ser aleatorios, porque rompo la estructura del tiempo.

Los datos frescos deben ser de mínimo el horizonte final de planeación. En series con estacionalidad, los datos frescos deben cubrir un ciclo de estaciones

completo. El equivalente a validación cruzada es la validación escalonada en origen.

Este es el equivalente de validación cruzada en mis series de tiempo, sin embargo, es costosa computacionalmente:

Validación escalonada en origen



Pronósticos ingenuos:

Benchmark (pronóstico ingenuo)

Caminata aleatoria: El último resultado es el pronóstico	**Promedio móvil:** El promedio de los últimos *n* meses (*n* a elección de juicio).
Caminata aleatoria Estacional: El último resultado en el mes de la estacionalidad es el pronóstico	Combinación de los anteriores

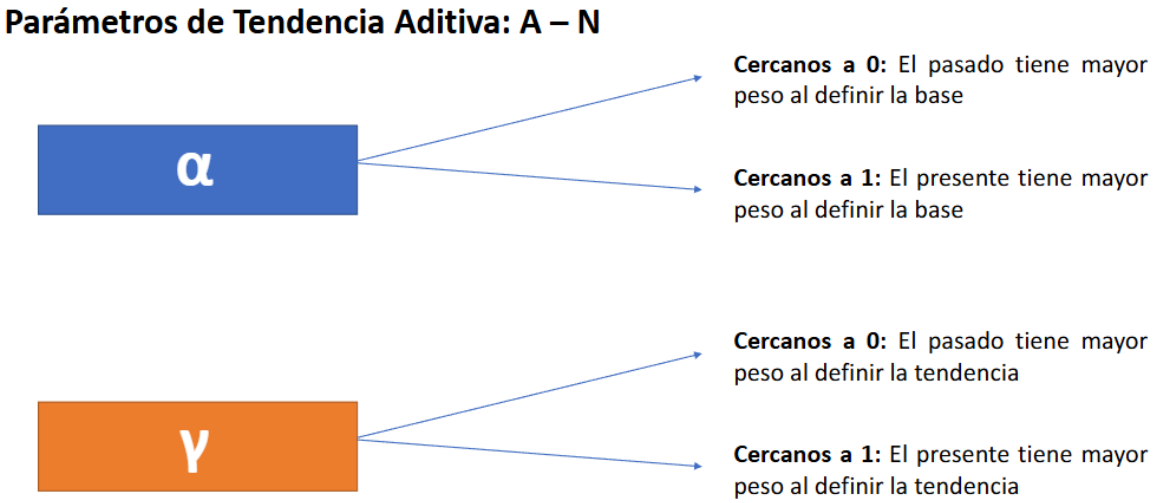
Caminata aleatoria sería KNN con K=1.

Suavización Exponencial

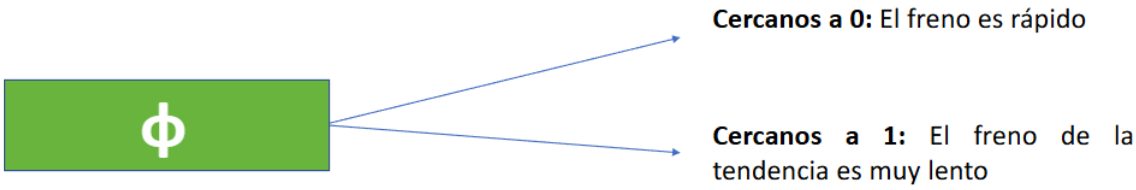
Es como un KNN ponderado. Tomo los últimos datos, sin embargo le doy más peso a los datos más recientes y menos a los datos más cercanos. Ese peso (nivel de ponderación) es un hiperparámetro a sintonizar. Después tengo la tendencia como hiperparámetro. También como último hiperparámetro tengo los pesos de la estacionalidad.

Además, hay que definir si es aditivo, multiplicativo o tiene un frenado.

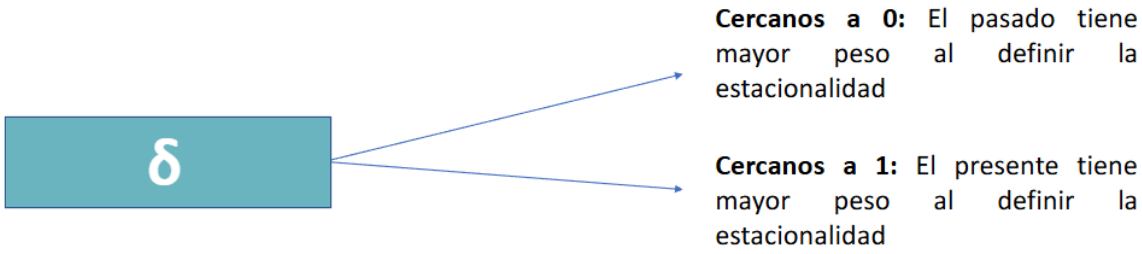
Entonces son 12 hiperparámetros más o menos.



Parámetros de Freno



Parámetros de Estacionalidad



OJO, MANEJAR SERIES DE TIEMPO EN R

Descriptiva

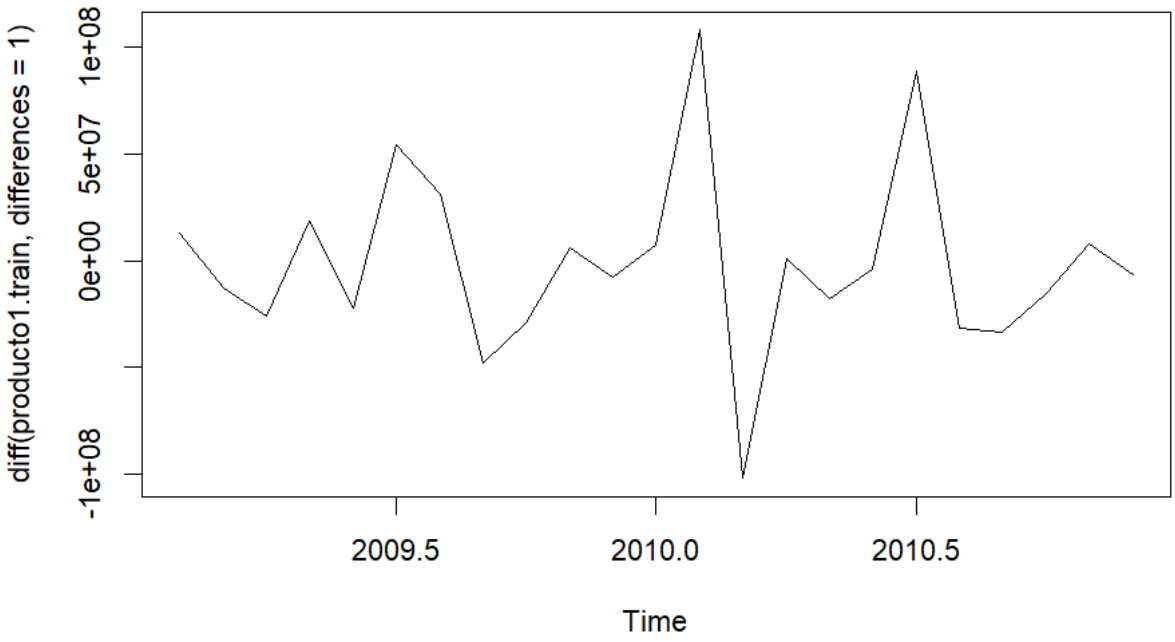
Primero, defino una estacionalidad y parto train y test. Ojo con esto

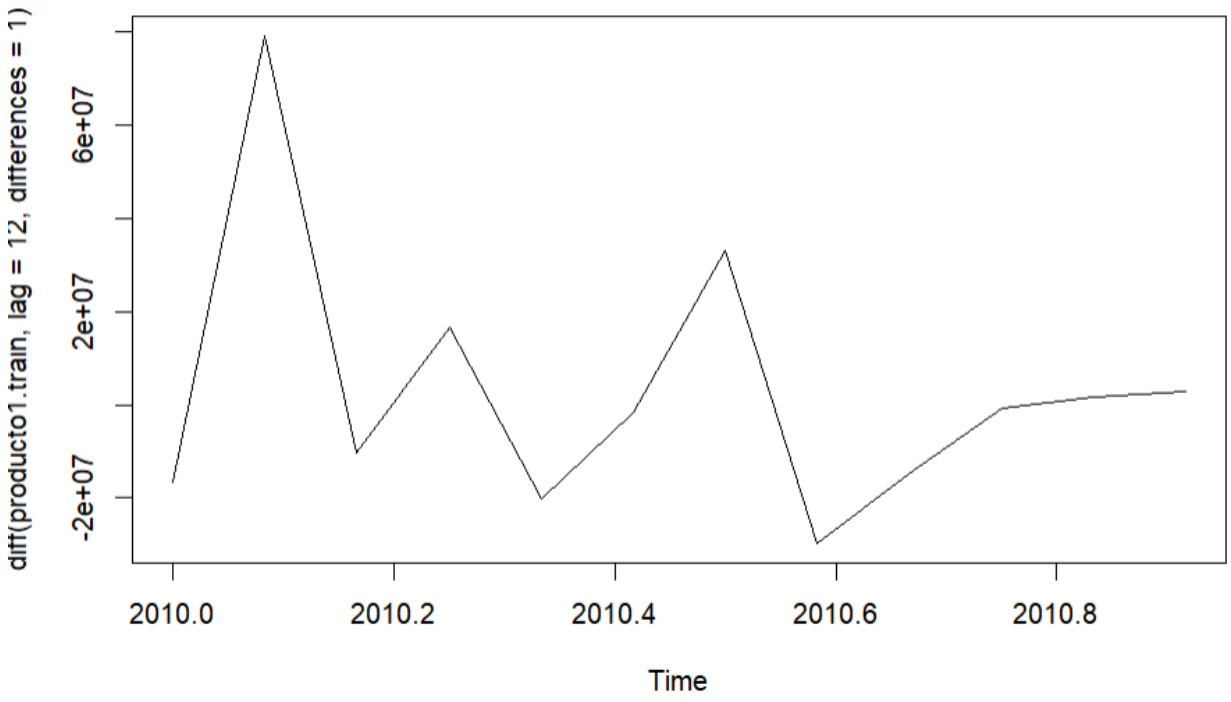
```
producto1 <- ts(festivos$FIESTA1, start=c(2009, 1), end=c(2011, 12), frequency=12)
producto1.train <- window(producto1, start=c(2009, 1), end=c(2010, 12))
```

```
producto1.test <- window(producto1, start=c(2011, 1), end=c(2
011, 12))
```

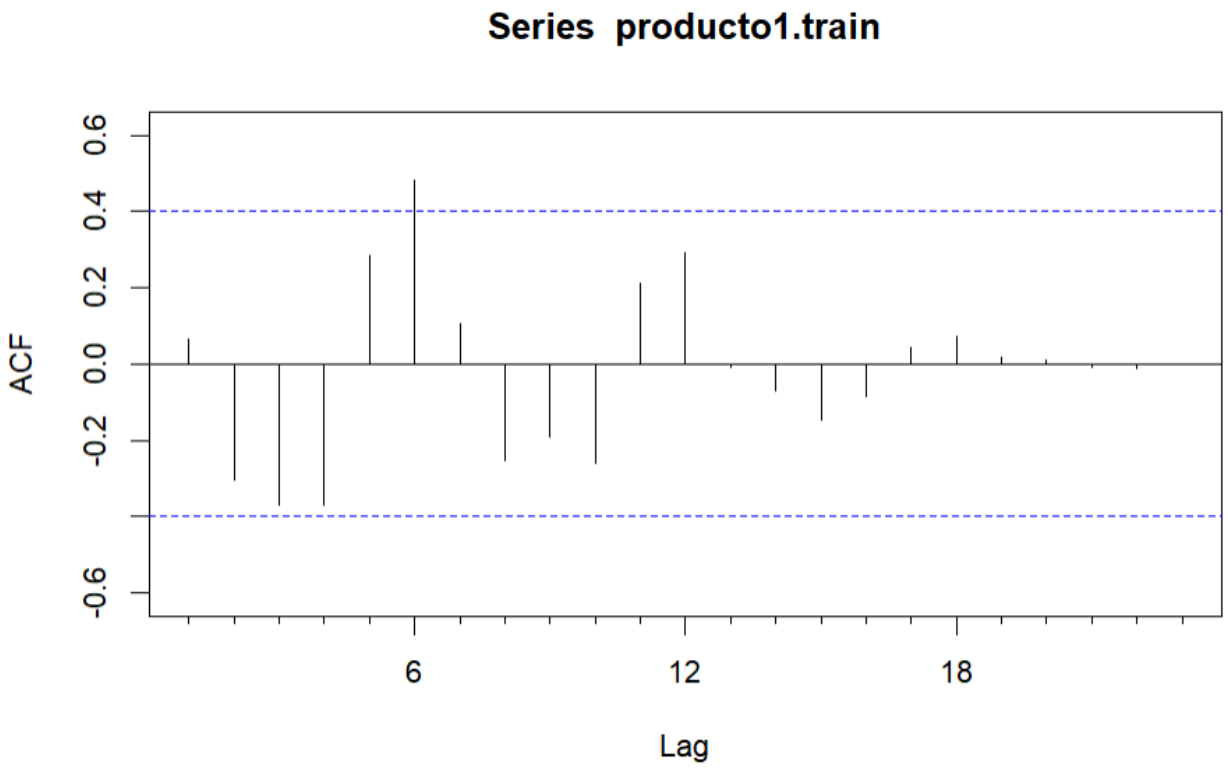
OJO con mi Data Understanding, gráficas:

Tendencia y estacionalidad

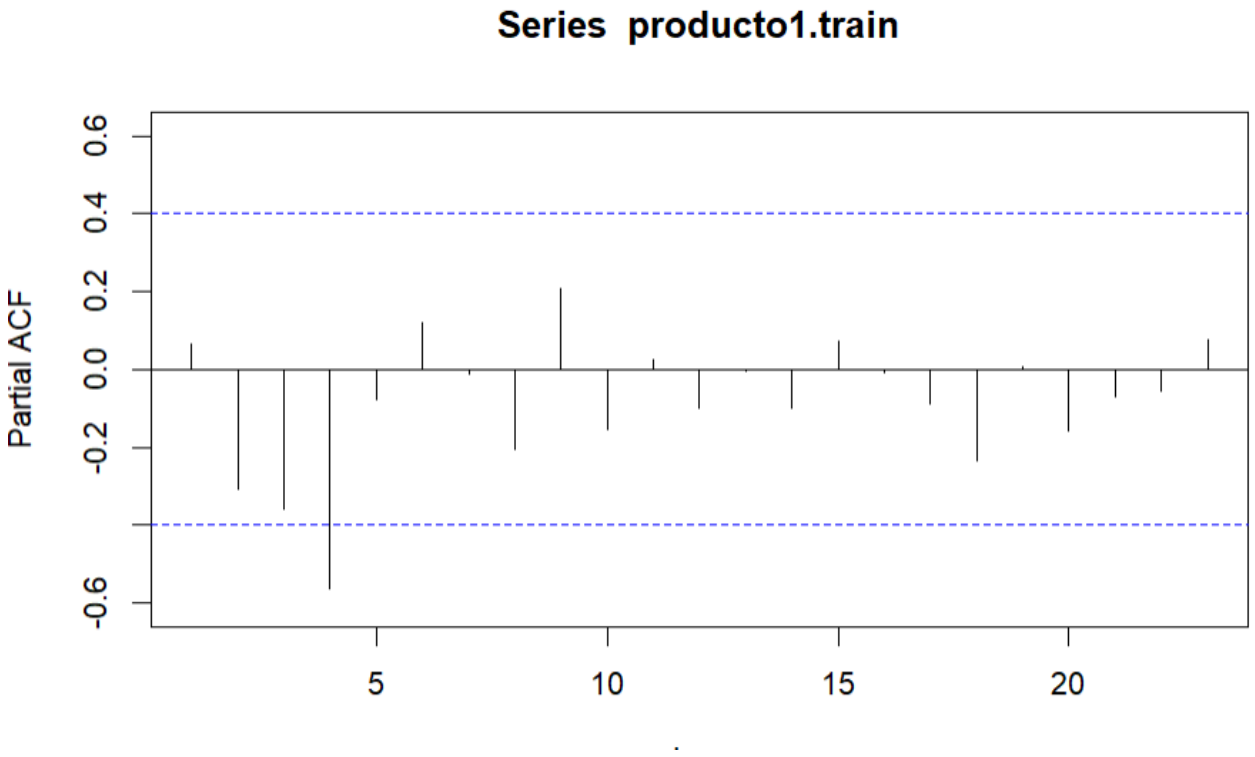




Autocorrelación:



Autocorrelación parcial:



Pero OJO, a las autocorrelaciones se les debe quitar el efecto de la estacionalidad y la tendencia.

REPASAR ESTA DESCRIPTIVA

Modelado:

ZZZ le dice que sintonice el solo los hiperparámetros

```
#modelo
modelo1<-ets(producto1.train, model="ZZZ",opt.crit="mse",ic
="aic")
summary(modelo1)
```

Resultado:

ETS(M,N,M)

(Base, Tendencia, Estacionalidad)

A: Aditivo

D: Damped

M: Multiplicativo

N: No

Los parámetros van de 1 a cero.

Importante ver cómo se interpretan estos coeficientes:

```
                    ME     RMSE      MAE       MPE     MAPE      MASE       ACF1
Training set -238.1617 14353260 10080092 -3.341236 14.21828 0.5333847 -0.3113882
```

MASE: Sí es mayor a 1 entonces mi modelo es peor que el ingenuo.

ARIMA

Bota seis coeficientes AR - I -MA. Los tres primeros son estacionales y los otros no estacionales.

- AR: Autocorrelación
- I: Tendencia
- MA: Autocorrelaciones parciales

```
#auto.arima busca el mejor arima.
modelo2<-auto.arima(producto1.train)
summary(modelo2)
```

Resultado:

```
Series: producto1.train
ARIMA(0,0,0)(2,1,0)[12]

Coefficients:
         sar1     sar2
      -0.4765  -0.3353
s.e.   0.1546   0.1541

sigma^2 = 3.613e+14:  log likelihood = -1091.99
AIC=2189.98   AICc=2190.41   BIC=2196.26

Training set error measures:
                   ME     RMSE      MAE       MPE     MAPE      MASE      ACF1
Training set 1714117 17059896 11159818 -2.096263 18.00593 0.7217075 0.0526297
```

¿Y si quiero meterle variables X, predictores? ARIMAX

A un ARIMA le puedo meter la serie de tiempo y predictores. Pero el predictor debe tener lag, y ojalá sea alto.

EJEMPLO DE VENTA DE PRODUCTOS DE CONSTRUCCIÓN Y LICENCIAS DE CONSTRUCCIÓN.

Resultados: OJO, yo puedo comparar los AIC entre ARIMA y ARIMAX.

```
Regression with ARIMA(0,0,0)(2,1,0)[12] errors

Coefficients:
         sar1     sar2    xreg
      -0.4914  -0.3985  0.1821
s.e.   0.1545   0.1505  0.0794

sigma^2 = 3.31e+14:  log likelihood = -1089.45
AIC=2186.91   AICc=2187.63   BIC=2195.28
```

Los modelos ARIMA son menos sesgados y pueden incluir más predictores. Sin embargo, la suavización exponencial se interpreta mejor.

Supuestos detrás de estos modelos:

Estacionareidad de los residuos: Los errores no deben tener ningún patrón visible. Para eso hay dos pruebas:

Dickey Fuller y Ljung Box.

```
adf.test(residuals(modelo1))
Box.test(residuals(modelo1), lag=20, type="Ljung-Box")
```

Pero ojo que en Dickey Fuller debo estar debajo de p value 0.05 y en el otro de Ljung Box debo estar por encima de 0.05.

Si fallan las pruebas entonces sospechamos que nuestro modelo no es robusto.

La elección de la base de test como el último año tiene un riesgo grave

Por eso debo hacer lo siguiente:

```
far2 <- function(x,h){forecast(Arima(producto1, order=c(0,0,
0),seasonal=c(2,1,0)), h=h)}
errores<-tsCV(producto1,far2,h=12,initial=24)
```

```r
#también se pueden usar ventanas móviles de tamaño k usando w
indow=k
erroresd<-as.data.frame(errores)[25:86,]
erroresd2<-(erroresd)^2
```

```
     h=1      h=2      h=3      h=4      h=5      h=6      h=7      h=8      h=9
28744677 62007885 28708940 34591584 31221234 41894767 40688351 62247778 29071040
    h=10     h=11     h=12
36130818 31733004 37559534
```

¡Entonces, esta prueba es importante para ver si REALMENTE ES BUENA LA SERIE DE TIEMPO!