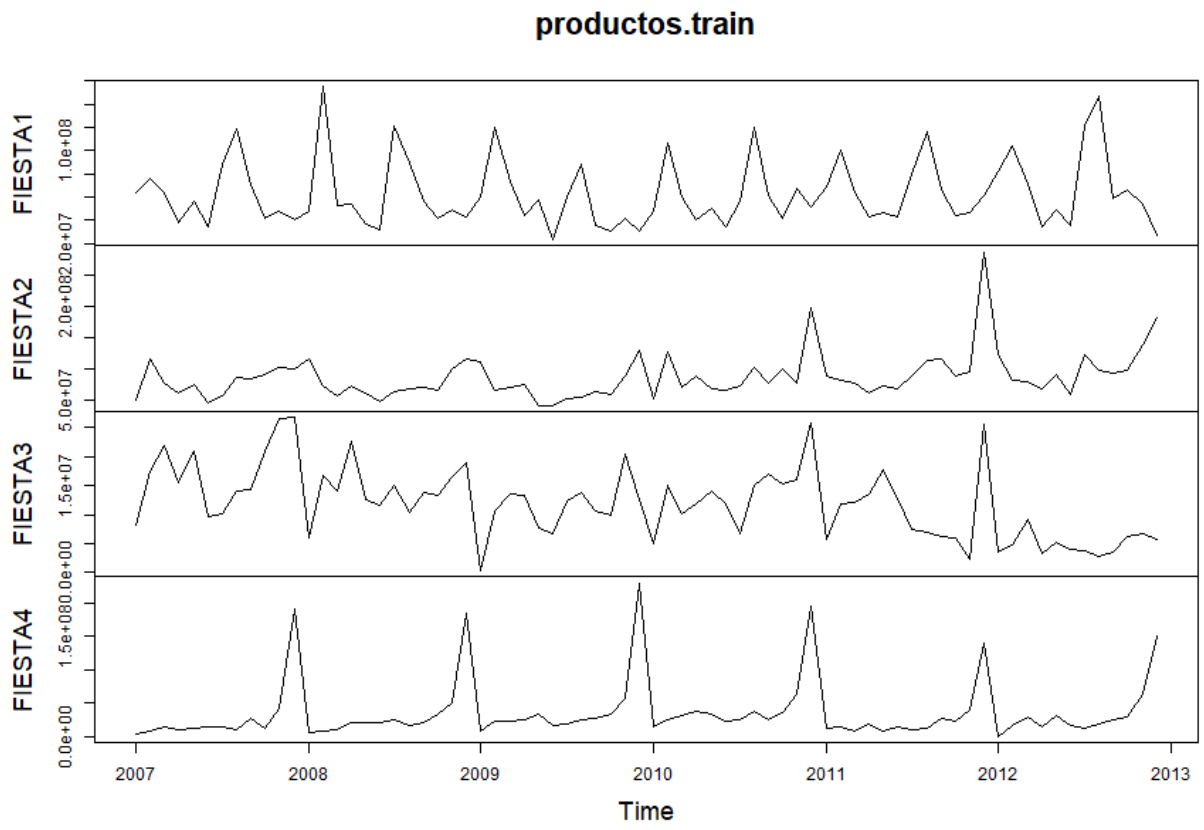
Clase 16

Ejercicios series de tiempo:



En los gráficos de la exploración se debe ver:

- Tendencia
- Estacionalidad
- Ciclos

Si veo estas cosas, debo diferenciar la tendencia y diferenciar la estacionalidad, para ver la serie plana:

- Hacer diferencias de febrero a marzo, marzo a abril, abril a mayo, etc. → Tendencia

- Hacer diferencias de febrero de un año a febrero de otro año → Estacionalidad

Esto se hace así:

```
#términos diferenciados
plot(diff(productos.train[,3], differences=1))
#el lag me permite hacerlo estacional
plot(diff(productos.train[,3], lag=12, differences=1))

#términos diferenciados
plot(diff(productos.train[,4], differences=1))
#el lag me permite hacerlo estacional
plot(diff(productos.train[,4], lag=12, differences=1))
```

¿Y cómo veo las autocorrelaciones?

Con Acf y Pcf. Pero ojo con que también hay que quitarle la estacionalidad, para ver bien la autocorrelación, esto con la doble diferenciación.

Resultados de Modelos:

Suavización Exponencial:

(Base, Tendencia, Estacionalidad)

(M,N,M) Significa: Multiplicativo - Nada - Multiplicativo

Aunque si me sale esto yo puedo cambiarlo, le cambiaría el “zzz”.

ARIMA:

ARIMA tiene estas partes:

Normal - Estacional

(0,1,1) - (0,0,1)

Para evaluar vemos el RMSE y el MASE (En MASE: 1 es el ingenuo, más de 1 es el ingenuo y menor que 1 es mejor que el ingenuo.)

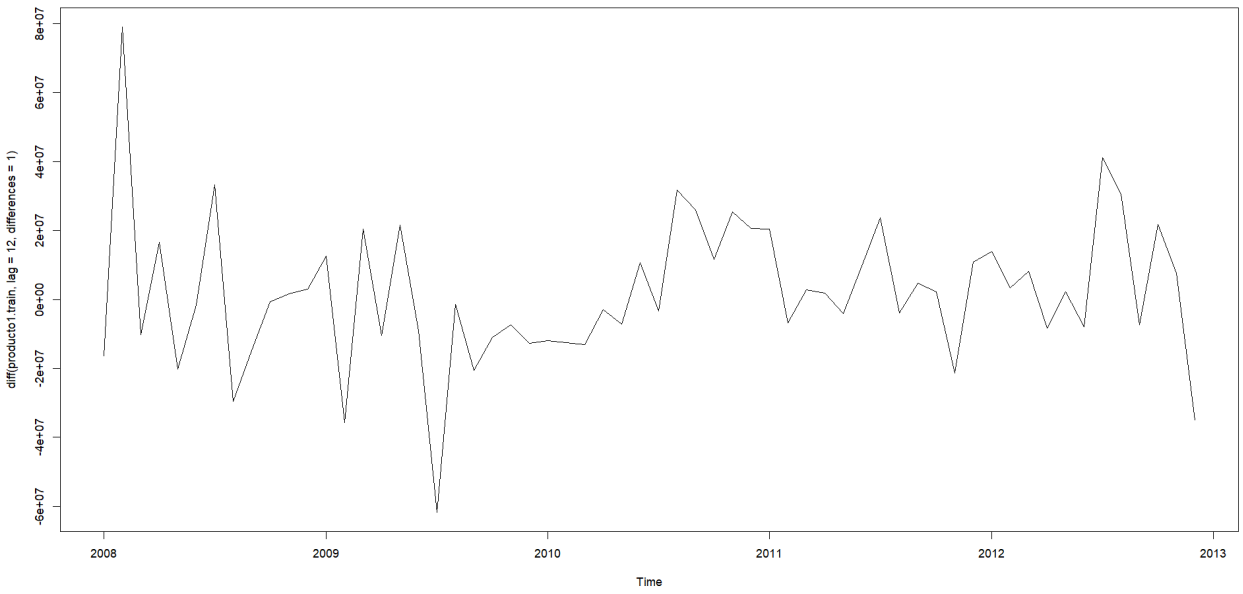
MAPE es un error porcentual, importante. 35.1086 diría un error porcentual de 35.1086%. El MAPE cuando más pequeño mejor.

Atípicos

Por ejemplo, después de esta línea:

```
#el lag me permite hacerlo estacional
plot(diff(producto1.train, lag=12, differences=1))
```

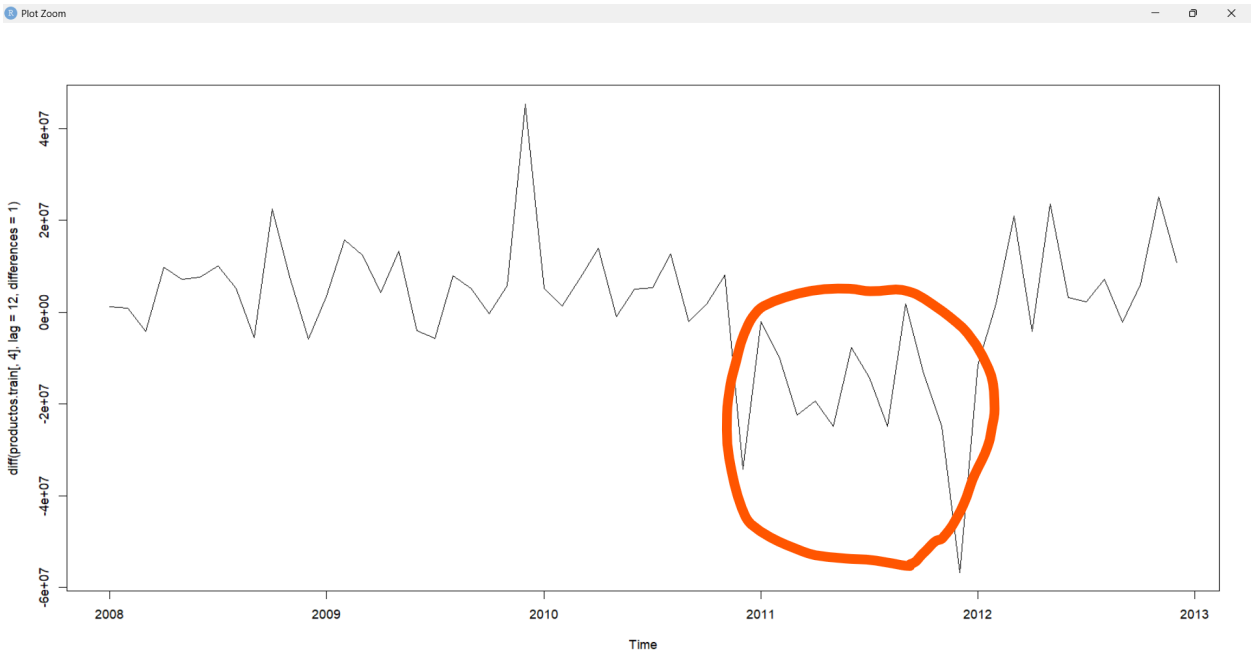
Me queda este outlier:



¿Cómo modelo un outlier en series de tiempo?

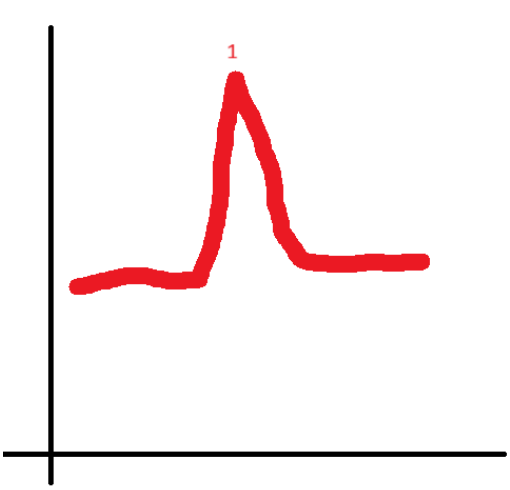
Si no puedo eliminarlo porque no es un error de medición, creo una variable dummy por CADA OUTLIER. Y con ello uso ARIMAX.

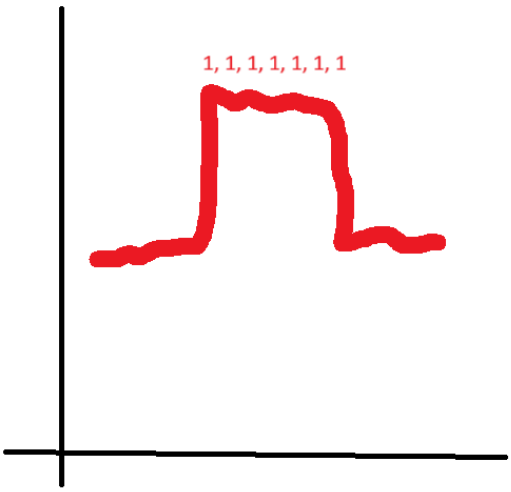
Y si tengo un año completo de Outliers:



Esto es Outliers de nivel, le pongo 1, 1, 1, a todo ese nivel (año)

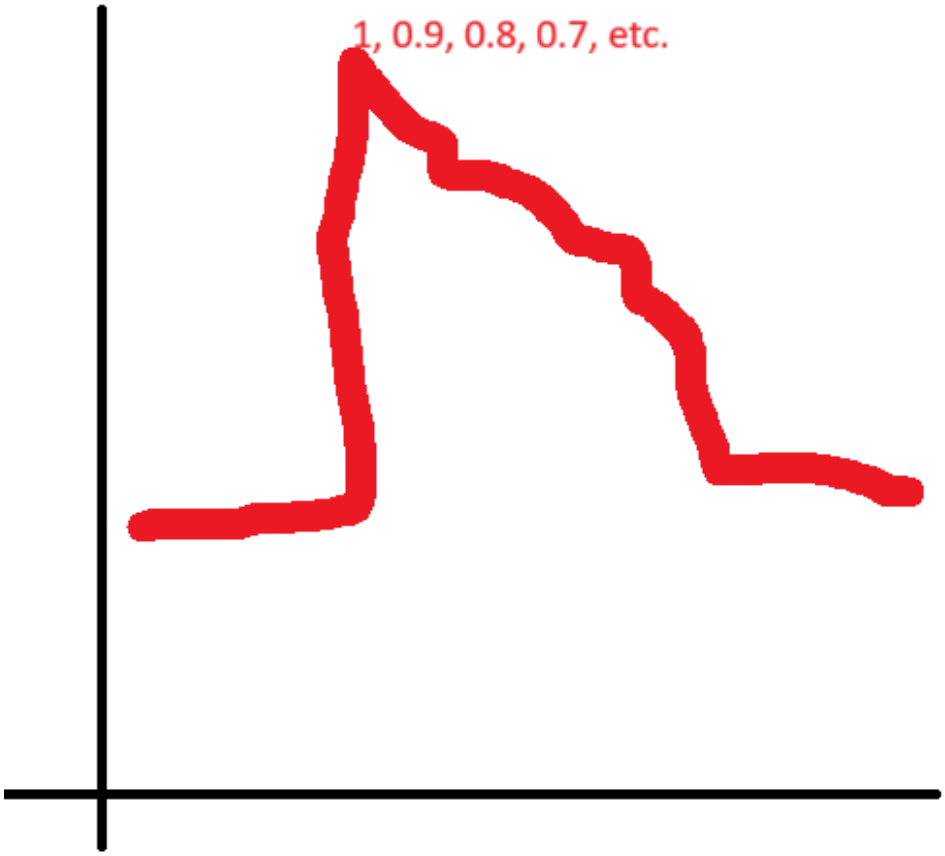
Entonces hay estas opciones:





Y una tercera:

Va bajando



¿Cómo detectar el outlier?

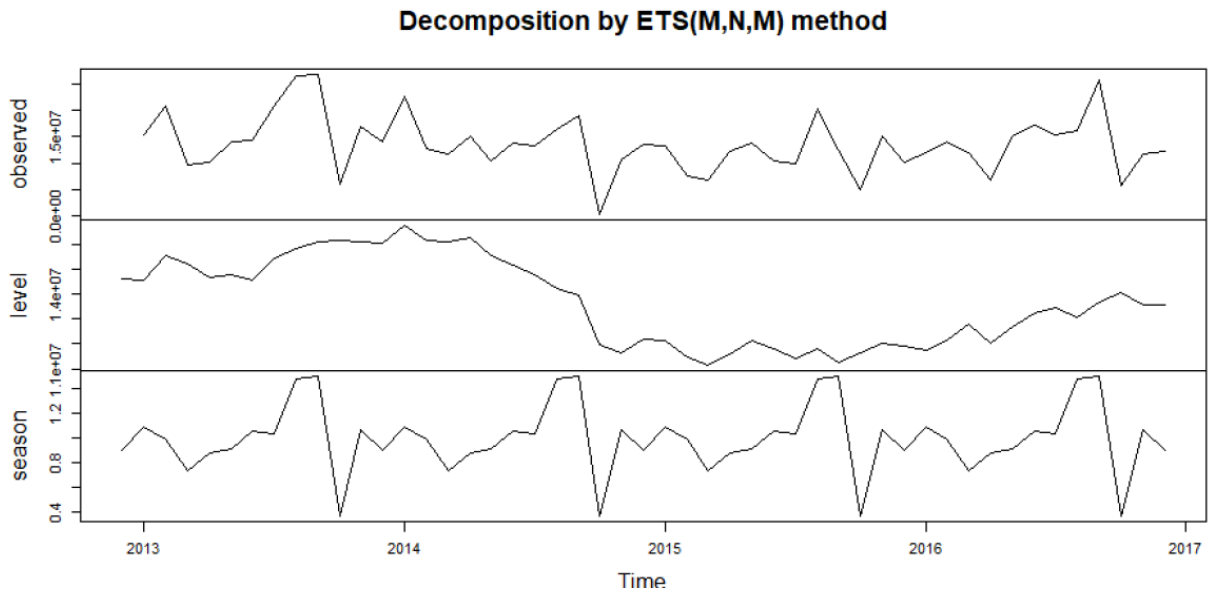
```
#Outliers
result<-tso(producto1.train)
```

Cierre

Predicción	Espacio de Hipótesis
Regresión	Linealidad/linealizable en la relación X y Y. Predictores escalares.

Naive-Bayes	Xs independientes y muchos categóricos (X); Rankear, Big Data
KNN	Puedo medir la cercanía a partir de los X’s
Árboles	Predictores categóricos e interacciones
Redes neuronales	Están hechas para predecir cualquier función. Teorema de aproximación universal. Esto ayuda cuando tengo muchos datos y no tengo los X’s de antemano (Imágenes, textos, videos, etc.) → Necesito una buena representación.
SVM	Topología no es cartesiana
Ensambles	La idea de los ensambles (que pueden ser de cualquier cosa) es que los puntos de vista diversos realmente funcionan mejor.

Preparación del parcial


Decomposition by ETS(M,N,M) method
observed
level
season
0.0e+00
1.5e+07
1.4e+07
1.1e+07
1.2
0.8
0.4
2013
2014
2015
2016
2017
Time